

本地 RAG 检索增强生成演示文档

1、项目简介

本项目实现完全本地运行的 PDF 知识库问答 Demo，不调用任何云端 API，所有模型、向量库全部部署在本机。

实现功能：加载 PDF 文档，文本自动分片，生成向量存入本地 Chroma 数据库，检索文档片段后交给大模型回答问题。

严格约束：大模型只能依据 PDF 内部内容作答，文档不存在的信息直接提示无相关内容，禁止幻觉编造。

2、技术栈

编程语言：Python

框架：LangChain

大模型：Ollama qwen2:1.5b-instruct

向量数据库：Chroma

文档加载：PyPDFLoader

3、执行流程

- ① PDF 文档加载
- ② RecursiveCharacterTextSplitter 文本分割，设置 chunk_size=500，重叠 80
- ③ OllamaEmbeddings 生成本地向量
- ④ 存入 Chroma 本地向量库
- ⑤ 用户提问，检索 top3 相关文档片段
- ⑥ 送入提示词约束大模型输出答案

4、项目难点

- 1) 文本切片大小需要调优，切片过大会语义混杂，过小丢失上下文。
- 2) 提示词约束，防止大模型产生幻觉，输出文档以外的虚假信息。

3) 全部本地离线运行，不需要网络、不需要付费 API 密钥。

5、测试样例问题

1.这个 RAG 项目使用什么大模型？

2.RAG 完整执行步骤是什么？

3.本项目如何防止大模型幻觉？