

本地 RAG 演示测试文档

版本: V1.0

项目简介

本 RAG 演示项目, 基于 FAISS 向量数据库、Ollama 本地大模型实现 PDF 文档问答。

完全不调用云端 API, 全部计算在本地电脑完成。

技术组件

1. 文档解析: PyPDF
2. 文本切分: RecursiveCharacterTextSplitter, 块大小 512, 重叠 80
3. 向量库: FAISS-CPU
4. 嵌入模型: all-MiniLM-L6-v2
5. 大模型: qwen2:1.8b
6. Web 界面: Gradio

项目能力

1. 支持上传 PDF 构建私有知识库
2. 多轮对话, 携带上下文记忆
3. 回答附带原文片段溯源, 降低幻觉
4. 向量持久化保存, 重启程序无需重新解析 PDF

测试问答参考

Q: 这个项目使用什么向量库?

A: FAISS-CPU

Q: 块大小设置多少?

A: 512, 重叠 80

Q: 是否需要调用云端 API?

A: 不需要, 全部本地运行。

注意事项

Ollama 后台服务必须提前启动, 否则项目无法运行。